Your Paper 中文

陆翔

2023 年 3 月 26 日

摘要

这是摘要

目录

1 介绍

1.1 利用图像分析自动估计动物体重的研究现状

1.2 本文的研究目标与内容

1.3 本文的组织架构

2 原理与方法

2.1 数据收集

2.2 预处理

这一章节的总流程图，见图1。

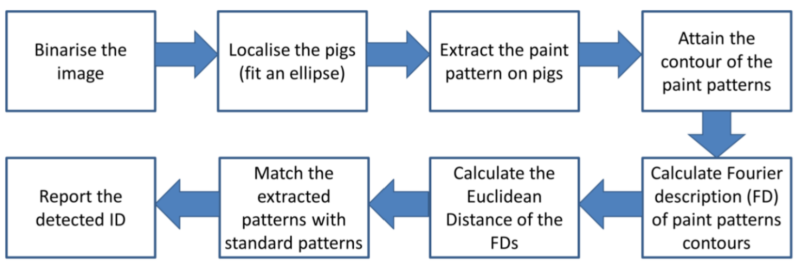

图 1: 流程概述，初步图片，待修改

2.2.1 初步裁剪

首先，对图片进行初步分割，确定喂食器和猪圈地板的位置。确定地板的范围后，我们将图片边缘处相机机盖裁剪去除。由于喂食器的色泽与猪的身体相近，将其排除也有助于提高后续检测的准确率。

2.2.2 基于局部自适应直方图均衡的对比度加强

为了加强提取轮廓的效果，需要先增加图片的对比度。这里我选择了局部自适应的直方图均衡算法（regionally adaptive histogram equalization）。

图 2: 裁剪边框前

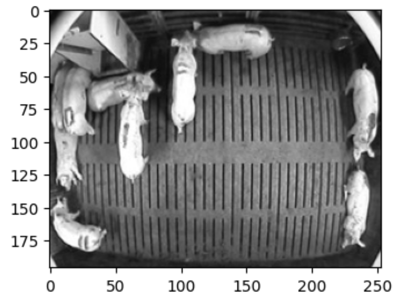

图 3: 裁剪边框后

先介绍传统的全局直方图均衡算法的数学原理，以单通道的灰度图片为例。假设图片灰度值可取$\{0,1,\ldots,L-1\}$，大小为$M\times N$，记灰度值为i的像素点数量为n_i，则有$MN=\sum_{i=0}^{L-1}n_i$。归一化直方图的对应分量$p_i=\frac{n_i}{MN}$。设输入像素点的灰度为i，则输出的灰度为$T(i)$

$$T(i)=\lfloor(L-1)\sum_{j=0}^{i}p_j\rfloor \tag{1}$$

假如L足够大时，我们可将离散的灰度i近似处理为连续变量。从图片中随机取一点，记对应的连续随机变量为$X\in[0,L-1]$，概率密度函数为$p_X(x)$，概率累积函数为$F_X(x)$。式(1)对应的变换为

$$Y:=H(X)=(L-1)F_X(X) \tag{2}$$

计算Y的概率密度函数

$$p_Y(y)=p_X(x)|\frac{dH(x)}{dx}|^{-1}=\frac{1}{L-1},\ y\in[0,L-1] \tag{3}$$

可见无论X分布如何，经过该变换，Y满足均匀分布，更好利用了灰度值范围，图片的对比度增强。但由于实际的灰度是离散的，只能使得新图片的灰度直方图大致均匀。

当原图片的灰度取值范围较小时，传统的全局直方图均衡算法表现较好；但当灰度取值范围较大时，则不然。

而局部自适应的xxx，其方法如下。

2.2.3 基于Otsu算法的图像二值化

用Otsu算法选择阈值，将灰度图片转化为二值图片。Otsu法能最大化

二值分类的类间方差，且只用到图片的灰度直方图。其原理如下。

设M, N, n_i, p_i, L的定义与之前章节一致。从图片中随机选取一个像素点，记其灰度值为随机变量I，则$\Pr(I = i) = p_i$。

若选择阈值$T(k) = k \in N$，使得灰度属于$[0, k]$的像素点被分类为c_1，灰度属于$[k+1, L-1]$的像素点被分类为c_2。则像素点属于c_i的概率为

$$\begin{aligned} \Pr(c_1, k) &= \sum_{i=0}^{k} p_i & (4) \\ \Pr(c_2, k) &= 1 - \Pr(c_1, k) & (5) \end{aligned}$$

这样的分类与k有关，但为了符号上的简洁，以下将参数k略去，例如$\Pr(c_i) := \Pr(c_i, k)$。

属于c_1时，由贝叶斯公式，I的条件期望为

$$\mathbf{E}(I|c_1) = \sum_{i=0}^{k} i \Pr(i|c_1) = \frac{1}{\Pr(c_1)} \sum_{i=0}^{k} i p_i \tag{6}$$

类似地，属于c_2时的条件期望为

$$\mathbf{E}(I|c_2) = \frac{1}{\Pr(c_2)} \sum_{i=k+1}^{L-1} i p_i \tag{7}$$

显然，条件期望和期望满足

$$\mathbf{E}(I) = \sum_{i=1,2} \Pr(c_i) \mathbf{E}(I|c_i) \tag{8}$$

我们定义类间方差为

$$\sigma_B^2 = \sum_{i=1,2} \Pr(c_i) [\mathbf{E}(I|c_i) - \mathbf{E}(I)]^2 \tag{9}$$

，而Otsu算法选择的阈值k_{Otsu}即最大化类间方差

$$k_{Otsu} = \arg \max_{k \in N, 0 \le k < L} \sigma_B^2(k) \tag{10}$$

再根据计算得到的阈值将输入灰度图片$f(x, y)$变换为黑白图片$g(x, y)$

$$g(x, y) = \begin{cases} 1, & f(x, y) > k_{Otsu} \\ 0, & \text{otherwise} \end{cases} \tag{11}$$

2.3 图像分割

2.3.1 基于最小二乘法的椭圆拟合

我们使用椭圆来近似猪的俯视图。椭圆可以用二阶多项式方程的解表示：

$$F_{\mathbf{a}}(x,y)=\mathbf{x}^{\mathbf{T}}\mathbf{a}=0 \text{ 且 } \mathbf{a}^{\mathbf{T}}\mathbf{C}\mathbf{a}>0 \tag{12}$$

其中

$$\mathbf{a} = [a,b,c,d,e,f]^T \tag{13}$$

$$\mathbf{x} = [x^2,xy,y^2,x,y,1]^T \tag{14}$$

$$\mathbf{C} = \begin{pmatrix} \begin{pmatrix} 0 & 0 & 2 \\ 0 & -1 & 0 \\ 2 & 0 & 0 \end{pmatrix} & O_{3\times3} \\ O_{3\times3} & O_{3\times3} \end{pmatrix}_{6\times6} \tag{15}$$

为了唯一确定系数，我们规定

$$\mathbf{a}^{\mathbf{T}}\mathbf{C}\mathbf{a}-1=0 \tag{16}$$

对于某组轮廓的点集$\{(x_i,y_i)|i=1,\ldots,N\}$，记数据矩阵

$$\mathbf{X}=\begin{pmatrix} x_1^2 & x_1y_1 & y_1^2 & x_1 & y_1 & 1 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ x_i^2 & x_iy_i & y_i^2 & x_i & y_i & 1 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ x_N^2 & x_Ny_N & y_N^2 & x_N & y_N & 1 \end{pmatrix} \tag{17}$$

，则$\mathbf{a}$的最小二乘估计为

$$\hat{\mathbf{a}}_{OLS}=\arg\min_{\mathbf{a}} \|\mathbf{X}\mathbf{a}\|^2 \text{ s.t. } \mathbf{a}^{\mathbf{T}}\mathbf{C}\mathbf{a}-1=0 \tag{18}$$

这是一个带约束的优化问题，使用拉格朗日乘子法求解

$$f(\mathbf{a},\lambda)=\|\mathbf{X}\mathbf{a}\|^2+\lambda(1-\mathbf{a}^{\mathbf{T}}\mathbf{C}\mathbf{a}) \tag{19}$$

令f的偏导数为0，我们得到方程组()

$$\begin{cases} \mathbf{X}^{\mathbf{T}}\mathbf{X}\mathbf{a}= & \lambda\mathbf{C}\mathbf{a} \\ \mathbf{a}^{\mathbf{T}}\mathbf{C}\mathbf{a}= & 1 \end{cases} \tag{20}$$

注意到对于(20)的解，有$\|\mathbf{Xa}\|^{\mathbf{2}} = \lambda$。所以多组解中，与λ的最小非负解对应的$\mathbf{a}$即为所求的$\hat{\mathbf{a}}_{OLS}$。

2.3.2 基于聚类选取最佳椭圆

2.4 体重估计

2.4.1 线性回归分析

3 实验

4 结论与展望